

Analyse des troubles du sommeil à partir de données Kaggle

Ce rapport présente le travail de traitement et d'analyse réalisé à partir de plusieurs bases de données issues de Kaggle portant sur le sommeil et la santé mentale.

L'objectif était d'étudier les facteurs associés aux troubles du sommeil (durée de sommeil, qualité, habitudes de vie, état psychologique) et de produire, sous Google Colab, des graphiques permettant de visualiser ces relations.

1. Présentation des bases de données

Les données ont été téléchargées depuis la plateforme Kaggle en recherchant les mots-clés « sleep », « sleep disorders », « sleep health » et « mental health ». Parmi plusieurs jeux de données, nous avons retenu un ensemble structuré en plusieurs fichiers CSV afin de séparer les informations sociodémographiques, les habitudes de sommeil et les indicateurs psychologiques. Un premier fichier contient les caractéristiques sociodémographiques des individus : participant_id, Age, Gender, Education_Level, Employment_Status, Occupation. Un second fichier décrit les habitudes et la qualité du sommeil : sleep_hours, physical_activity_level, sleep_quality_score, sleep_disorder, caffeine_intake, screen_time. Un troisième fichier regroupe pour chaque participant_id les principales variables de sommeil. Un quatrième fichier contient des indicateurs de santé mentale : anxiety_score, depression_score, stress_level, life_satisfaction_score, social_support_score. Grâce à la clé participant_id, nous avons pu relier ces tables et disposer, pour un même individu, de son profil complet.

2. Recherche et sélection des données sur Kaggle

La première étape a consisté à identifier des jeux de données pertinents sur Kaggle. Les principaux critères de sélection étaient : • un lien explicite avec le sommeil et les troubles du sommeil ; • la présence de variables continues (heures de sommeil, scores de qualité, scores d'anxiété, etc.) ; • une documentation minimale (description des variables, taille de l'échantillon) ; • un format exploitable (CSV) et une taille raisonnable pour travailler dans Colab. Les fichiers CSV sélectionnés ont ensuite été importés dans Google Colab à l'aide de la bibliothèque pandas.

3. Nettoyage et préparation des données

Avant toute analyse, les données ont été nettoyées et préparées.

3.1 Vérification des types et du format Nous avons vérifié la structure de chaque fichier (lignes, colonnes, types) pour nous assurer que des variables comme Age, sleep_hours ou anxiety_score soient bien numériques.

3.2 Gestion des valeurs manquantes Les valeurs manquantes ont été repérées. Lorsque leur nombre était faible, les lignes ont été supprimées. Sinon, de simples imputations (moyenne pour les quantitatives, modalité la plus fréquente pour les qualitatives) ont été utilisées.

3.3 Doublons et

cohérence des identifiants Nous avons contrôlé l'unicité de participant_id. Les doublons parfaits ont été supprimés ; en cas de conflit entre fichiers, la version la plus complète a été conservée. 3.4 Valeurs aberrantes Nous avons exclu les valeurs manifestement impossibles (âge négatif, plus de 16h de sommeil, scores hors échelle). 3.5 Nouvelles variables Des catégories ont été créées : sommeil court (< 6h), normal (6-8h), long (> 8h), ainsi que des groupes d'âge ou des indicateurs binaires de trouble du sommeil.

4. Exploitation statistique des données

Nous avons d'abord calculé des statistiques descriptives (moyennes, médianes, écarts-types) pour les principales variables de sommeil et de santé mentale. Puis, des analyses bivariées ont été menées : comparaison de la qualité du sommeil selon l'activité physique, relation entre temps d'écran et heures de sommeil, lien entre scores d'anxiété/de dépression et présence d'un trouble du sommeil. Des tableaux croisés, comparaisons de moyennes et corrélations ont été utilisés.

5. Visualisation des résultats avec Google Colab


Les graphiques ont été réalisés sous Google Colab avec pandas, matplotlib et seaborn. Ils permettent de résumer visuellement les tendances mises en évidence par les analyses statistiques et de mieux comprendre les profils de sommeil observés.

6. Interprétation générale et limites de l'étude

De manière générale, la durée et la qualité du sommeil apparaissent liées à certains facteurs de mode de vie (activité physique, temps d'écran, caféine) et à l'état psychologique (anxiété, dépression, stress). Cependant, l'échantillon n'est pas représentatif de toute la population et les données, auto-rapportées, sont sujettes à des biais. La nature transversale du jeu de données ne permet pas de conclure à des relations causales, seulement à des associations.


7. Analyse détaillée des graphiques

7.1 Distribution des heures de sommeil




L’histogramme montre une distribution centrée sur 6-8 heures, en cohérence avec les recommandations usuelles. Le pic autour de 7h indique qu’une majorité d’individus ont un sommeil « normal ». Les faibles dormeurs (< 4h) constituent un sous-groupe vulnérable, souvent associé dans la littérature à une fatigue chronique et à des difficultés de concentration. Les gros dormeurs (> 10h), bien que peu nombreux, peuvent refléter un sommeil peu réparateur ou des états dépressifs où l’hypersomnie est fréquente. Ce graphique sert de base pour identifier des profils à risque dans la suite de l’analyse.

7.2 Heures de sommeil par genre




Le boxplot par genre met en évidence surtout des différences de variabilité. Les médianes de sommeil sont proches, mais certains groupes (en particulier Non-Binary) présentent une dispersion plus forte et davantage de valeurs extrêmes. Cela peut traduire une exposition plus importante au stress ou à des conditions de vie instables. Les groupes Male et Female affichent des distributions plus resserrées, tout en laissant apparaître quelques cas atypiques. Ce graphique suggère que le genre influence davantage la stabilité du sommeil que sa durée moyenne.

7.3 Relation entre qualité du sommeil et heures de sommeil



Le nuage de points, complété par une droite de régression, montre une relation légèrement positive entre la quantité de sommeil et la qualité perçue : en moyenne, dormir plus améliore la qualité, mais la corrélation reste faible. La dispersion importante des points indique que d'autres facteurs jouent un rôle majeur : stress, anxiété, ruminations, qualité de l'environnement de sommeil, etc. On observe par ailleurs des individus qui dorment peu mais déclarent un bon sommeil, ce qui renvoie à l'idée d'« efficacité du sommeil », et d'autres qui dorment beaucoup mais rapportent une mauvaise qualité, typique de certains troubles.

7.4 Prévalence des troubles du sommeil



Le graphique en barres compare la fréquence de deux troubles principaux : l'insomnie et l'apnée du sommeil. Les effectifs relativement proches montrent que les dimensions psychologiques (insomnie) et physiologiques (apnée) sont toutes deux importantes dans l'échantillon. L'insomnie est souvent liée à des difficultés d'endormissement ou de réveils nocturnes associés au stress ou à l'anxiété, tandis que l'apnée du sommeil renvoie à des anomalies respiratoires, avec un impact cardiovasculaire possible. Cela confirme que l'étude du sommeil doit articuler facteurs mentaux et facteurs corporels.

8. Conclusion

Ce rapport montre comment des données publiques issues de Kaggle peuvent être exploitées pour analyser les troubles du sommeil, depuis la collecte jusqu'à la visualisation. L'articulation des informations sociodémographiques, des habitudes de vie et des scores de santé mentale permet d'adopter une approche multidimensionnelle. Les graphiques enrichissent l'interprétation en mettant en évidence des profils à risque et en rappelant que la quantité de sommeil, la qualité perçue, le genre, le stress et les troubles physiologiques interagissent fortement. Ce travail constitue une base solide pour un projet académique ou un mémoire sur les troubles du sommeil.